

## R-EDL

$$\alpha_X(x) = e_X(x) + C \cdot a_X(x), \quad \forall x \in \mathbb{X} = \{1, 2, \dots, C\},$$

### 1. $\alpha_X(x)$ —— Dirichlet 分布的浓度参数 (Concentration Parameter)

- 这是最终计算出的参数，用来构建 Dirichlet 分布 (Dirichlet PDF)。
- Dirichlet 分布被用来模拟分类概率的分布。 $\alpha$  的值越大，意味着对该类别的分布越“尖锐”或越确定。

### 2. $e_X(x)$ —— 证据 (Evidence)

- 这是神经网络直接从输入样本中学习到的数值（通常经过 Softplus 等激活函数确保为非负值）。
- 它代表了模型在数据中找到的支持样本属于类别  $x$  的实际证据量。证据越多， $e$  越大。

### 3. $a_X(x)$ —— 基础率 / 先验概率 (Base Rate)

- 代表在没有看到任何数据证据之前，对类别  $x$  的先验信念。
- 文中指出，这通常被设定为**均匀分布** (Uniform distribution)。例如，如果有  $C$  个类别，每个类别的  $a_X(x)$  通常是  $1/C$ 。这意味着在没看图之前，我们认为它是任何一类的概率是均等的。

### 4. $C$ —— 先验权重 (Prior Weight) / 类别总数

- 这是一个标量系数，文中称为“先验权重”。
- 在传统的 EDL 设置中，这个权重被**强制固定为类别的总数**（即  $\mathbb{X} = \{1, 2, \dots, C\}$  中的  $C$ ）。
- 它的作用是控制先验分布 (Base rate) 对最终结果的影响权重。

这个公式表达了**主观逻辑 (Subjective Logic)** 的核心思想：**最终的信念 ( $\alpha$ ) = 观察到的证据 ( $e$ ) + 初始的先验底色 ( $C \cdot a$ )**

在标准 EDL 设置下（假设  $a_X(x) = 1/C$ ），公式其实可以简化为：

$$\alpha_X(x) = e_X(x) + C \times \frac{1}{C} = e_X(x) + 1, \quad \forall x \in \mathbb{X}$$

这意味着：即便模型没有找到任何证据 ( $e = 0$ )，参数  $\alpha$  也会默认为 1。这保证了 Dirichlet 分布在没有证据时退化为均匀分布（即完全不确定状态），而不是数学上无意义的状态。

$$P_X(x) = \frac{e_X(x) + 1}{\sum_{x' \in \mathbb{X}} e_X(x') + C} = \frac{\alpha_X(x)}{S_X}, \quad u_X = \frac{C}{\sum_{x \in \mathbb{X}} e_X(x) + C} = \frac{C}{S_X}, \quad \forall x \in \mathbb{X}$$

$C$  (先验权重) 是一个“非必要且僵硬的设置”。

- **问题：**为什么要强行让先验权重等于类别数  $C$ ？如果类别数很大（比如 100 类），先验权重就会高达 100。这会导致即便模型收集了一定量的证据（比如  $e = 10$ ），也会被巨大的先验权重（100）淹没，导致预测结果偏差或反直觉。

假设我们正在训练一个图像分类模型，具体设定如下：

#### 1. 任务难度：100 分类任务（即 $C = 100$ ）。

#### 2. 模型表现：模型对某张图片非常确信它是“类别 1”，并且收集到了大量的证据。

#### 3. 证据数值：

- 类别 1 的证据： $e_1 = 100$ （非常高，代表非常确定）。
- 其他 99 个类别的证据：0。
- **总证据量：** $\sum e = 100$ 。

我们的直觉告诉我们：既然模型找到了 100 个证据支持它是类别 1，且没有证据支持其他类别，**那么预测概率应该接近 100% (1.0)，对吧？**

在传统 EDL 中，先验权重  $W$  被强制固定为类别数  $C$ 。

- **公式：**  $P(x) = \frac{e(x)+1}{\sum e+C}$
- **参数：**  $e(x) = 100, \sum e = 100, C = 100$

**计算过程：**

$$P(\text{类别1}) = \frac{100 + 1}{100 + 100} = \frac{101}{200} \approx \mathbf{0.505}$$

**结果分析：**

**50.5%。**

这是非常反直觉的！模型明明找到了 100 个单位的证据，但在传统 EDL 的数学框架下，这 100 个证据被巨大的类别数量（100 个类别的先验权重）给“稀释”了。模型表现得像是在猜硬币一样，即使它实际上已经“看”得很清楚了。

---

**R-EDL 的改进：**把这个固定的  $C$  变成一个可学习或可调节的超参数，不再让它死板地等于类别总数。

$$\alpha_X(x) = \left( \frac{e_X(x)}{W} + \frac{1}{|\mathbb{X}|} \right) W$$

- **展开括号：**将外面的  $W$  乘进去：  
 $\alpha_X(x) = e_X(x) \cdot \frac{W}{W} + \frac{W}{|\mathbb{X}|}$
- **消除  $W$ ：**第一项的  $W$  约掉，剩下  $e_X(x)$ 。
- **定义  $\lambda$ ：**第二项是  $\frac{W}{|\mathbb{X}|}$ 。这里  $|\mathbb{X}|$  就是类别总数  $C$ 。作者定义了一个新的超参数  $\lambda = \frac{W}{C}$ 。
- **最终结果：**

$$\alpha_X(x) = e_X(x) + \lambda$$

- **传统 EDL：**  
它默认  $W = C$ （先验权重 = 类别数）。  
因此，它相当于强制  $\lambda = C/C = 1$ 。  
公式变成： $\alpha = e + 1$ 。  
这意味着：无论什么任务，只要证据为 0，Dirichlet 分布的参数就必须默认为 1。
- **R-EDL：**  
它认为  $W$  不应该被死板地绑定在  $C$  上。  
通过引入  $\lambda$ ，公式变成： $\alpha = e + \lambda$ 。  
\*这意味着： $\lambda$  可以是 0.1，可以是 10，也可以是 1。它变成了一个可以调节的超参数 (Hyperparameter)\*。

这个公式的本质是 **Laplace 平滑 (Laplace Smoothing)** 的泛化。

- $e_X(x)$  是观测到的数据。
- $\lambda$  是平滑项（截距）。

R-EDL 通过这个公式告诉我们：“我们在构建不确定性模型时，**初始的信念（截距  $\lambda$ ）应该是可以根据任务调整的，而不是由类别数量死板决定的。**”实验证明，通常设置  $\lambda$  为较小的值（如 0.1 或 0.01）能获得比传统 EDL（默认 1）更好的效果。

假设我们正在训练一个图像分类模型，具体设定如下：

1. **任务难度：100 分类任务**（即  $C = 100$ ）。

2. **模型表现**：模型对某张图片非常确信它是“类别 1”，并且收集到了大量的证据。

3. **证据数值**：

- 类别 1 的证据： $e_1 = 100$ （非常高，代表非常确定）。
- 其他 99 个类别的证据：0。
- 总证据量**： $\sum e = 100$ 。

在 R-EDL 中，我们引入超参数  $\lambda$ （论文推荐设为较小的值，如 0.1），不再受类别数  $C$  的绑架。

- 公式**： $P(x) = \frac{e(x)+\lambda}{\sum e+C\cdot\lambda}$
- 参数**： $e(x) = 100, \sum e = 100, C = 100$ , 设定  $\lambda = 0.1$

**计算过程**：

$$P(\text{类别1}) = \frac{100 + 0.1}{100 + (100 \times 0.1)} = \frac{100.1}{100 + 10} = \frac{100.1}{110} \approx \mathbf{0.91}$$

**结果分析**：

**91%。**

这个结果就合理多了。因为  $\lambda$  很小，先验分布（Base Rate）对结果的干扰大大降低，最终概率主要由实际观察到的证据（Evidence）主导。

如果我们将  $\lambda$  设得更小（例如 **0.01**），结果会更接近 1.0：

$$P = \frac{100.01}{100 + 1} = \frac{100.01}{101} \approx \mathbf{0.99}$$

## 总结对比

| 方法     | 证据量 | 类别数 (C) | 先验设置               | 计算出的概率       | 评价                   |
|--------|-----|---------|--------------------|--------------|----------------------|
| 传统 EDL | 100 | 100     | 强制 $W = 100$       | <b>50.5%</b> | <b>严重低估</b> （被类别数稀释） |
| R-EDL  | 100 | 100     | 设置 $\lambda = 0.1$ | <b>91.0%</b> | <b>符合直觉</b> （准确反映证据） |

这就是 R-EDL 论文想要证明的核心观点：**如果你做的是多分类任务（类别很多），传统 EDL 的公式会因为“死板的先验权重”而强行压低正确类的概率，导致模型不仅学得慢，而且在证据充足时依然不够自信。** R-EDL 通过松绑这个设置，解决了这个问题。